HiveQL Queries and Views

Munteanu Bianca-Ștefania



Ce este HiveQL?





HiveQL (Hive Query Language) este un limbaj de interogare similar cu SQL, utilizat pentru a interoga și gestiona datele stocate în Apache Hive, un sistem de data warehousing construit pe Apache Hadoop.



01

Sintaxă Familiară

Utilizatorii familiarizați cu SQL se adapteaza usor 02

Operațiuni de Bază

SELECT, INSERT, UPDATE, DELETE...

03

Funcții de Agregare

COUNT, SUM, AVG, MIN, MAX...

04

Tipuri de Date Complexe

ARRAY, MAP și STRUCT

05

Optimizare pentru Big Data

Volume mari de date stocate în HDFS

06

Execuție prin MapReduce

Transformă interogările HiveQL în joburi MapReduce



Utilizare Colecții - ARRAY

Array: Colecție ordonată de elemente de același tip.

```
CREATE TABLE employees (
             STRING,
 name
 salary
             FLOAT,
 subordinates ARRAY<STRING>,
 deductions
             MAP<STRING, FLOAT>,
 address
             STRUCT<street:STRING, city:STRING, state:STRING, zip:INT>
PARTITIONED BY (country STRING, state STRING);
hive> SELECT name, subordinates FROM employees;
             ["Mary Smith", "Todd Jones"]
John Doe
Mary Smith ["Bill King"]
Todd Jones []
Bill King
```

Utilizare Colecții - MAP

Map: Colecție de perechi cheie-valoare, unde cheile sunt unice.

```
CREATE TABLE employees (
             STRING,
  name
  salary
             FLOAT,
  subordinates ARRAY<STRING>,
  deductions
             MAP<STRING, FLOAT>,
  address
             STRUCT<street:STRING, city:STRING, state:STRING, zip:INT>
PARTITIONED BY (country STRING, state STRING);
hive> SELECT name, deductions FROM employees;
             {"Federal Taxes":0.2, "State Taxes":0.05, "Insurance":0.1}
John Doe
Mary Smith {"Federal Taxes":0.2, "State Taxes":0.05, "Insurance":0.1}
Todd Jones {"Federal Taxes":0.15, "State Taxes":0.03, "Insurance":0.1}
Bill King {"Federal Taxes":0.15, "State Taxes":0.03, "Insurance":0.1}
```



Utilizare Colecții - STRUCT

Struct: Colecție de elemente eterogene, fiecare având un nume și un tip specific.

```
CREATE TABLE employees (
              STRING,
  name
  salary
              FLOAT,
  subordinates ARRAY<STRING>,
  deductions
              MAP<STRING, FLOAT>,
  address
              STRUCT<street:STRING, city:STRING, state:STRING, zip:INT>
PARTITIONED BY (country STRING, state STRING);
hive> SELECT name, address FROM employees;
John Doe
            {"street":"1 Michigan Ave.", "city": "Chicago", "state": "IL", "zip":60600}
Mary Smith {"street":"100 Ontario St.","city":"Chicago","state":"IL","zip":60601}
Todd Jones {"street":"200 Chicago Ave.", "city": "Oak Park", "state": "IL", "zip":60700}
Bill King {"street":"300 Obscure Dr.", "city": "Obscuria", "state": "IL", "zip":60100}
```

Funcții

Funcții Matematice:

- ROUND
- FLOOR
- CEIL (CEILING)

```
hive> SELECT upper(name), salary, deductions["Federal Taxes"],
> round(salary * (1 - deductions["Federal Taxes"])) FROM employees;

JOHN DOE 100000.0 0.2 80000
MARY SMITH 80000.0 0.2 64000
TODD JONES 70000.0 0.15 59500
```

Funcții de Agregare:

- COUNT
- AVG
- MIN/MAX

```
hive> SET hive.map.aggr=true;
```

```
hive> SELECT count(*), avg(salary) FROM employees;
```

60000.0 0.15 51000

4 77500.0

BILL KING

Clauza WHERE

Utilizarea operatorilor logici

```
SELECT * FROM employees
WHERE country = 'US' AND state = 'CA';
```

Sintaxa:

SELECT coloane **FROM** tabel **WHERE** condiție;

Utilizarea funcțiilor în WHERE

LIKE și RLIKE

• LIKE: Permite potrivirea stringurilor care încep, se termină sau conțin un anumit substring

• RLIKE (REGEXP): O extensie Hive care permite utilizarea expresiilor regulare Java




GROUP BY și HAVING

- GROUP BY: Utilizat pentru a grupa rândurile care au aceleași valori într-una sau mai multe coloane. Acesta este adesea folosit împreună cu funcții de agregare
- HAVING: Utilizat pentru a filtra grupurile de rânduri create de clauza GROUP BY.
 Spre deosebire de WHERE, HAVING poate filtra rezultatele pe baza funcțiilor de agregare.

SELECT coloane, funcții_agregare FROM tabel WHERE condiție GROUP BY coloane HAVING condiție_agregare;

```
hive> SELECT year(ymd), avg(price_close) FROM stocks
    > WHERE exchange = 'NASDAQ' AND symbol = 'AAPL'
    > GROUP BY year(ymd)
        > HAVING avg(price_close) > 50.0;
1987
        53.88968399108163
       52.49553383386182
1991
      54.80338610251119
1992
      57.77071460844979
1999
2000
       71.74892876261757
2005
       52.401745992993554
```



JOIN


- Utilizat pentru a combina rânduri din două sau mai multe tabele pe baza unei coloane comune.
- Hive suportă doar equi-join-uri.



Map-side JOIN


- Optimizare care permite efectuarea operațiilor de join în faza de mapare atunci când toate tabelele, cu excepția unuia, sunt suficient de mici pentru a fi încărcate în memorie.
- Elimină necesitatea fazei de reduce, accelerând execuția
- Se poate seta marimea tabelului mic

hive.mapjoin.smalltable.filesize=25000000





• sortează datele pe fiecare reducer în parte



SELECT coloane FROM tabel SORT BY coloană ASC | DESC;


SELECT SalesYear, Amount
FROM tbl_Sales
SORT BY SalesYear;



- asigură ordonarea globală a datelor.
- toate datele sunt trecute printr-un singur reducer pentru a obține un set de date sortat global

SELECT coloane FROM tabel ORDER BY coloană ASC | DESC;

ORDER BY




SELECT SalesYear, Amount FROM tbl_Sales ORDER BY SalesYear;



DISTRIBUTE BY

SELECT SalesYear, Amount
FROM tbl_Sales
DISTRIBUTE BY SalesYear;

SELECT coloane FROM tabel DISTRIBUTE BY coloană;




 controlează modul în care datele sunt distribuite între reduceri, bazat pe valorile coloanelor specificate.



CLUSTER BY

SELECT SalesYear, AmountFROM tbl_SalesCLUSTER BY SalesYear;

SELECT coloane FROM tabel CLUSTER BY coloană;




 combinație de DISTRIBUTE BY și SORT BY, folosind aceleași coloane pentru ambele operații.

View

- permite salvarea unei interogări și tratarea acesteia ca un tabel
- un construct logic care nu stochează date
- Hive nu suportă view-uri materializate
- Reducerea Complexității Interogărilor
- Restricţionarea Accesului

CREATE VIEW shorter_join AS
SELECT * FROM people JOIN cart
ON (cart.people_id=people.id) WHERE firstname='john';

- Stergere View DROP VIEW IF EXISTS shipments;
- Modificare View ALTER VIEW shipments SET TBLPROPERTIES ('created_at' = 'some_timestamp');





View pe tabel dinamic

 Un tabel dinamic utilizează tipuri de date complexe, cum ar fi MAP, ARRAY şi STRUCT, pentru a stoca date flexible.

```
CREATE EXTERNAL TABLE dynamictable(cols map<string, string>)
ROW FORMAT DELIMITED
   FIELDS TERMINATED BY '\004'
   COLLECTION ITEMS TERMINATED BY '\001'
   MAP KEYS TERMINATED BY '\002'
STORED AS TEXTFILE;

CREATE VIEW orders(state, city, part) AS
SELECT cols["state"], cols["city"], cols["part"]
FROM dynamictable
WHERE cols["type"] = "request";
```

THANK YOU!

